面向法定豁免推理的执行证据驱动技能进化

摘要

可复用指令为权重固定的小型语言模型提供学习接口，但有用的初始记忆不等于后续经验仍能改善它。我们在法定豁免分类与估值任务中研究这一区别：回答需要保留各项独立适用替代，并赋予对应保护金额。执行证据驱动技能进化将任务专注执行教学与完整输出效用准入结合：教师根据已释放训练目标及真实执行错误修订法律程序，基于重放的发布同时检验漏列与错误申报。冻结 Qwen3-8B 在 128 个来源、八批学习后，于另外 128 个来源隔离案件上评价。最终七条目库取得 95.46%的分类 F1 与 87.90%的估值 F1，分别高于强空库 30.98 和 32.02 个百分点。相对自身首批库，持续进化增加 11.95 个分类百分点，来源配对的同时调整区间为[7.33,16.60]。在共同执行器接口下，其分类和估值分别高于 SkillCommit 论文适配 27.49 和 23.08 个百分点。匹配控制将终库效用与教师可见执行证据及准入与选择策略相连。结果表明，可编辑程序能够在不更新参数的情况下持续改善这一法律分类任务。

1. 引言

法律规则适用不止于回忆相关条款：回答必须将事实条件与每项适用替代相连，并计算其后果。LegalBench (Guha 等 2023 年)在法律推理分类中区分规则回忆与规则适用。OpenExempt (Servantez 等 2026 年)通过带有符号参考解的自动生成法条推理问题，使这些要求可以测量。

外部经验为参数固定的模型提供可编辑的学习接口。自然语言教训可以概括反复出现的错误，进化式 playbook 可以跨任务传递程序，ExpeL (Zhao 等 2024 年)与 ACE (Zhang 等 2025 年)研究了这些做法。在法律应用中，这种程序需要说明条款何时适用、哪些替代同时成立，以及如何将法定上限转化为资产对应金额。这些是执行器需要落实的指令，而非需要回忆的更多法条文本。

对于经验整合，合理的抽象与有用的程序之间的区别十分重要。Trace2Skill (Ni 等 2026 年)从逐轨迹教训归纳可迁移程序，ReasoningBank (Ouyang 等 2025 年)则组织成功和失败经历中的策略。SkillCommit (He 和 Yang 2026 年)进一步在扩大技能适用范围前检验行为兼容性。我们关注小型冻结模型对法律替代的执行：观察到的声明错误，能否形成随着新案到来仍有用的程序？这需要区分初次获得技能库的价值与持续修订技能库的价值。

我们通过面向豁免分类和估值的执行证据驱动技能进化研究这一问题。保存一批盲预测后，教师接收已释放的参考输出、真实父库答案和逐声明错误。教师修订一个任务的指令，同时保持另一个任务的投影。编辑可以修改适用条件和程序表达，也可以在保留规则的同时加入脱敏执行示例。学习状态是共享且有界的文本技能库，执行器继续直接生成法律答案。

发布决策与这些生成答案的质量相连。控制器在全部已遇到训练来源上评估完整提案和依赖一致的编辑分量。准入保持当前批次及全已见来源的原生与完整输出 F1，同时限制历史均值损失。完整输出评分同时计入错误申报、漏列与错金额。保留的历史失败见证为后续教学提供信息。任务专注修订与效用准入由此将法律程序内容与目标模型的实测执行相连。

评价包含按时间顺序的学习流，以及后续来源隔离案件上的冻结库比较。第一批结束后固定的技能库检验后续进化的增量价值。同版本控制考察教师可见执行证据及准入与选择策略，空库、静态库和经验学习库提供互补参照。这些证据在共同法律任务接口下，区分初始知识获取、后续新案学习和最终技能库效用。

完整比较在 128 个新来源上取得 95.46%的 EC F1 和 87.90%的 EV F1。相对自身首批库，终库增加 11.95 个 EC 百分点，该继续学习收益在预定比较族调整后仍为正。本研究的贡献是面向法律程序的执行驱动学习闭环，并分别提供初始技能库效用、后续进化及教师可见执行错误价值的证据。

2. 相关工作

基于经验的上下文适应。 外部学习方法在经验表示和整合方式上各有不同。ExpeL (Zhao 等 2024 年)从训练经历提取自然语言洞见，ReasoningBank (Ouyang 等 2025 年)从自行判断的成功和失败中提炼策略供后续检索。ACE (Zhang 等 2025 年)通过生成、反思和策展维护增量修订的 playbook，Trace2Skill (Ni 等 2026 年)则将并行的逐轨迹教训整合为可迁移技能目录。我们的研究聚焦固定法条回答接口下的程序，利用已释放训练标签和观察到的执行错误学习，并将最终技能库推理与学习流分开。

行为验证与法条推理。 Factoring Statutory Reasoning (Holzenberger 和 Van Durme 2021 年)将规则适用分解为语言理解子任务，支持更细粒度的诊断。JustifIT-QA (Dalla Noce 等 2026 年)将法条检索与判别模型引导的回答修订结合。在可复用经验方面，GSE (Yang 等 2026 年)结合技能关系图、聚类整合与历史重放，对候选技能库进行验证。SkillCommit (He 和 Yang 2026 年)保留实例特定补丁，检验跨实例迁移及机制兼容性，并提交保持已验证行为的高层抽象。它也在 OpenExempt 上评价，将法律规则适用纳入行为验证式技能进化的研究。OpenExempt (Servantez 等 2026 年)提供专家构建的法条表示、生成案件和可计算目标，支持分别分析分类与估值。我们利用这种分离，研究任务专注程序修订及同时考虑原生与完整输出效用的准入。机制控制检验真实执行证据和发布策略如何影响学成的程序；固定首批库比较检验进一步进化是否帮助后续新案。

3. 任务与学习问题

我们研究冻结语言模型能否通过积累和修订可复用法律程序改善法条推理。每个来源案件提供事实、法条和可适用法域的判定结果。豁免分类任务（EC）识别每个适用的资产与条款替代组合。豁免估值任务（EV）进一步给出各替代组合的受保护金额。两个任务共享案件事实，但独立作答。EV 根据自己的输入判断适用资格；已给先决步骤识别可适用法域，而不是已解 EC 答案。

目标是基准所定义的各项独立适用替代。一项具体豁免和一项一般财产豁免可能同时与某资产相关。对应保护金额是替代申报，不是要求将其合并为全财产范围的分配方案。全部参考输出遵循固定基准的构建过程及其提供的法条文本。

令B为文本技能库，F_θ为参数固定的执行器。一条技能声明公开法律命名空间、支持任务、适用条件、程序和排除条件。一个共享条目可以包含分开的 EC 和 EV 指令块。对来源c及任务h，公开法域与任务投影$P_h(B;c)$选择下发给执行器的指令：

$$\hat{y}_{c,h}(B) = F_\theta\left(x_{c,h}, P_h(B;c)\right).$$

其中$x_{c,h}$包含案件事实、已给先决步骤和法条。投影选择相关指令文本。执行器决定资产资格、适用条款及申报金额。学习状态是技能库文本，而非模型权重。

执行器使用共享公开条款标签及案件内的字面资产引用。这些引用标识已给文本中的字符串。解码器通过查表还原对应字符串。空库和学习库条件使用同一接口。EC 指令位于案件之前，EV 指令位于案件之后。公开资产引用不携带适用资格判定或参考金额。

4. 执行证据驱动技能进化

学习闭环将观察到的声明错误转化为程序，并在发布前检验每项修订。它包含两个相连阶段：任务专注执行教学和完整输出效用准入。

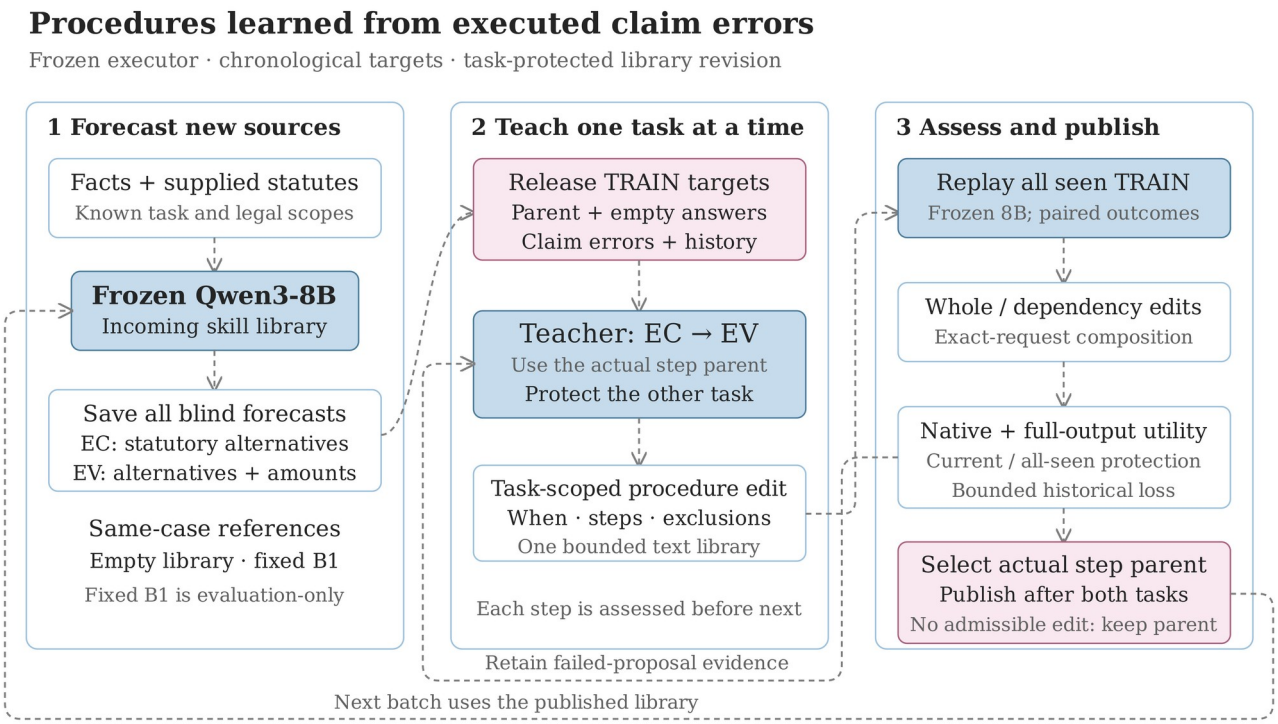


图 1. 执行证据指导受任务保护的法律程序修订。保存全部新来源预测后才释放训练目标。中间与右侧阶段依次用于 EC 和 EV：每步选择结果成为下一步的真实父库，两项任务完成后发布批次技能库。整包提案与依赖一致组合在全部已遇到训练来源上按原生及完整输出效用检验。相同请求复用同一次真实回答。有界失败提案证据用于后续教学，已发布技能库服务下一批。固定 B1 参照仅用于评价。学习流结束后固定实际末库，单独评价，不向学习回传反馈。

4.1. 任务专注执行教学

按时间组织证据。 学习器从空库开始，依次处理来源批次。先保存当前批次所有预测，再释放该批原参考输出。每批随后拥有一次 EC 专注和一次 EV 专注的教学机会。第一步被接收的修订成为第二步的真实父库。

教师看到当前案件和有界历史子集。证据包括公开事实与法条、原训练目标、真实父库与空库答案，以及执行器的实际回答接口。逐声明反馈通过固定基准匹配器区分漏列替代、错金额及额外预测。选定的模型实际输出片段补充这些观察结果。完整原始输出保留为证据来源。

程序与执行示例。 教师可以在当前任务投影内创建、更新、合并或移除技能文本。它区分指令不足与执行失误。前者可以修改适用条件、程序表达或排除条件。对于后者，保留已有法律知识前缀，添加或替换紧凑的脱敏执行示例。例如，示例可以展示一般财产替代应与满足条件的具体替代同时保留，而不记录某实例的资产名称或数值。

每项变化的技能与任务投影都绑定已释放训练来源。已有规则的锚点引用同一父投影。新引入的投影没有可以引用的同投影旧文本。来源标识和诊断理由不进入执行器的技能记忆。

任务保护。 EC 教学步骤保持 EV 投影不变，反之亦然。教师因此可以改进某个程序，而不暗中重写另一任务的指令。条目可以共享，但任务指令块分别校验。完整序列化技能库包含元数据和两个任务视图，使用同一 token 预算。

保留失败证据。 对每个教学任务，下次请求可以保留其最近一项未成功或部分提交的历史提案，最多携带八条真实重放见证。空操作或无关的成功编辑不清空该记录。历史候选输出保留其原提案库身份。当前父库的参考作答单独提供，因此旧输出不会被呈现为当前技能库下的新执行。

4.2. 完整输出效用准入

检验来源集合。 每项提案在全部已遇到的训练来源上检验。令D_t为当前批次，H_t为此前来源，$A_t = D_t \cup H_t$。对每个任务，控制器将候选与该教学步骤的真实父库比较。因此，有界教师通信不会缩减检验来源集合。

令$g_{S,h}(B)$为技能库B在来源集S及任务h上的平均分。准入同时使用原生 F1 与完整输出 F1：

$$g_{D_t,h}(B') \geq g_{D_t,h}(B), g_{A_t,h}(B') \geq g_{A_t,h}(B),$$

$$g_{H_t,h}(B') \geq g_{H_t,h}(B) - \varepsilon.$$

当H_t非空时应用历史约束。每项不等式分别检查 EC 和 EV，以及两种评分定义。准入变化还须严格提高当前批次的原生分或完整输出分，或减少当前批次格式失败、空目标或未计分资产申报计数。无效回答仍为零分。错误申报仍受到完整输出 F1 惩罚。格式与错误申报计数作为诊断报告，不再作为额外的零增加否决条件。

这些约束保持当前批次及全已见来源的聚合质量，同时允许有界历史权衡。检验对象是实际训练执行；个别案件可以改善或受损。token 预算和任务保护约束施加于同一实际下发候选。

整包与依赖一致修订。 控制器考虑完整提案，以及由可准入法律编辑分量构成的组合。分量依据公开法律上下文中实际共同可见的变化指令构建，其数量取决于提案及已遇到的上下文。组合在未准入分量上保留父指令，发布一个固定技能库。

每个组合请求都须在完整消息、schema 和生成参数上匹配已经测量的父库或提案请求。随后在实际组合库下解释已有原始回答。因此，选择作用于技能库，而不是构建逐案挑选有利答案的混合。

选择与发布。 在可准入整包和组合修订中，选择最大化被修改任务的全已见完整输出增益：

$G_h(B', B) = g^{full}_{A_t,h}(B') - g^{full}_{A_t,h}(B).$

完全相同时保留整包提案。实现先比较任务增益的最小值，再比较均值；在任务保护下，未修改任务的增益为零，因此该顺序等价于G_h。若两项修订均不可准入，则保留父库。两步教学后，实际发布结果相对最初批父库按同一准入合同检查。

学习闭环固定实际末批技能库用于评价。执行器始终直接生成 EC 答案与数字 EV 申报，技能条目不含数值算子。完全相同请求复用同一回答，生成成本计一次。别名不作为独立样本。

5. 实验设计

实验回答四个研究问题。**RQ1：** 在新来源上，最终冻结技能库相对空库、静态库及经验学习库有何效用？**RQ2：** 后续修订能否在 B1 所得技能库之外改善后续案件预测？**RQ3：** 保留训练标签与基于重放的准入时，教师直接看到执行证据还有何增量价值？**RQ4：** 完整输出效用准入与严格准入及选择策略相比如何？冻结比较回答 RQ1，时间顺序曲线及终库对 B1 库的比较回答 RQ2，两项同版本学习控制分别回答 RQ3 与 RQ4。

5.1. 数据与时间顺序学习

训练流包含通过固定 OpenExempt 过程生成的 128 个来源案件，每案有一个 EC 和一个 EV 视图。保留原事实、参考输出、顺序及法条材料。八个批次各含 16 个来源。保存全部预测条件后，释放当前批次目标。没有验证集划分。

生成器每案采样 2 至 4 项资产，夫妻案件比例参数设为 0.5，法域范围为 Arizona、Illinois、Oregon、Pennsylvania 和 Wisconsin。可选的无关事实和主观意见均关闭。训练与来源隔离 IID 评价共享这些设置。

来源隔离 IID 确认集包含按同一生成器及构建设置生成的另外 128 案。构建时排除训练及先前使用过的数据包来源 key。方法、必要控制、实际终库 hash、共同推理条件和统计族完成绑定后，才打开确认输入。先前已观察的评测与本次确认分开保留。

5.2. 比较对象与机制控制

比较包含强空库执行器、静态法条技能库、保留的经验学习库和学习得到的终库。同一 ACE 库通过原生接口及无损共同接口包装分别评价。这是同一学习库的两个接口。Trace2Skill–Text 提供离线、纯文本的轨迹学习比较，SkillCommit 论文适配提供任务级在线修补和行为验证整合。三项适配均使用已释放训练参考，教师请求模型及推理强度相同；附录 C 列出各方法的构建条件。

两项同版本控制针对当前机制。严格策略条件保留教师、锚点及有界历史，同时恢复原零回退、计数否决和原生增益选择策略，因此检验完整准入与选择策略束。教师证据条件保留效用策略、原标签、事实、法条、当前父库及公共执行器接口，同时向教师隐藏显式执行结果与带结果标签的反馈。控制器仍执行真实重放与准入，因此该条件检验教师直接看到执行证据的增量价值。

一份已完成的前序库作为历史方法版本参照保留，与匹配部件控制分开。额外独立学习构建仍暂缓。两项控制均已完成全部八批。原十条件比较在预测前绑定其实际技能库。后续 SkillCommit 补充先冻结实际第八批终库，再评价既有 128 来源 TEST 数据包，其两端点比较单独报告（附录 B.5）。

5.3. 指标与学习曲线

主要端点是原生逐案 EC 与 EV F1，分别在来源间取平均。固定评测器的资产匹配及金额容差保持不变。完整输出 F1 在每个来源内汇总真阳性、假阳性及假阴性，再在来源间取平均，包含未匹配或空目标资产上的申报。因此，原生与完整输出 F1 在案内使用不同聚合，两者数值不必满足固定大小关系。

时间顺序曲线报告每个新批次在目标释放前的首次作答。同案比较入批技能库、空库，以及在第一批恰好结束后固定的技能库快照。该快照用于评价，不作为教师或准入输入。B2 从同一技能库开始；后续批次测量进一步进化的作用。标签释放后的检验重放单独报告。

每次评价实验均先保存预测，再执行该次统一评分。来源配对重采样将每案 EC 和 EV 视图放在一起，刻画以实际冻结库为条件的不确定性。原比较族在确认输入打开前固定，后续 SkillCommit 补充保留其单独声明的两端点分析。报告包含无效输出、漏列、错金额、额外申报、实际技能编辑和下发任务块。真实原始生成、完全相同请求复用、教师响应与尝试、token 总量和耗时构成成本核算。

5.4. 实现设置

设置	数值
执行器	Qwen3-8B (Qwen Team 2025 年)，权重固定，BF16
运行环境	单个 A40 模型实例；四个 native worker；一个教师 worker
推理软件	vLLM 0.10.2；PyTorch 2.8.0
教师请求模型	`gpt-5.6-sol`，high reasoning effort
训练来源数 / 批次数	128 / 8
每批来源数	16
教学机会	每批一个 EC 步骤与一个 EV 步骤；最多 16 次成功响应
完整技能库预算	4,096 个执行器 tokenizer token
历史均值损失容差ε	F1 尺度 0.01，即一个百分点
执行器上下文 / 最大输出	32,768 / 8,192 tokens
解码	Seed 45；temperature 0.6；top-p 0.95；top-k 20；thinking 开启
教师历史提案记忆	每任务最多一个；每提案八条见证

设置	数值
上游生成器 / 评测器版本	`ec6fa2547431096588ce2d3ef107b8adc33cd4fe`

6. 结果

6.1. 新来源上的终库效用（RQ1）

最终库在法条分类与估值上均优于空库、静态库及保留的经验学习库（表 1）。其 EC F1 为 95.46%、EV F1 为 87.90%；强空库对应 64.48%和 55.88%，差值为 30.98 与 32.02 个百分点。相对 ACE 共同接口，差值为 28.87 与 20.98 个百分点。这四个效应的同时调整区间均为正（附录 B.4）。SkillCommit 论文适配取得 67.98%的 EC F1 和 64.82%的 EV F1，最终库对应 27.49 与 23.08 个百分点的增益在单独两端点补充中区间均为正（附录 B.5）。固定骨干保持模型容量不变；共同接口比较进一步表明，仅改变 ACE 的下发接口不能解释学成技能库的优势。第 6.3 节通过匹配学习控制，将终库效用与教师可见执行证据及发布策略相连。

表 1. 128 个来源隔离 IID 案件上的冻结库表现（%）。 EC 与 EV 为原生逐案 F1 的来源均值；Avg.是两者的描述性均值。粗体标出各列最高点估计。保留全部无效和不利输出，构建条件与成本另行报告。

冻结技能库	EC F1	EV F1	Avg.
强空库	64.48	55.88	60.18
静态法条技能库	60.40	55.34	57.87
ACE 原生接口	65.00	58.68	61.84
ACE 共同接口	66.59	66.92	66.75
Trace2Skill–Text	55.08	53.31	54.19
SkillCommit 论文适配	67.98	64.82	66.40
自身固定 B1 库	83.51	84.25	83.88
严格策略控制	80.29	**89.01**	84.65
教师隐藏执行证据控制	86.98	80.38	83.68
前序方法库	87.63	83.91	85.77
执行证据驱动技能进化	**95.46**	87.90	**91.68**

原十条件实验包含 2,560 条预测，先保存再进行该次统一评分。单独的 SkillCommit 实验新增 256 条真实预测，同样先保存再执行其自身评分，共同来源矩阵上合计 2,816 条预测。ACE 两行是一个学成 playbook 的两个接口。前序库是方法版本参照，严格策略与教师证据条件则是匹配学习控制。表 B3 另列完整输出质量、精确目标匹配和格式失败。

6.2. 时间顺序进化（RQ2）

持续进化在首批学成库之外改善新案回答。在 B2–B8 全部 112 个来源上，进化库相对自身固定 B1 库将原生 EC F1 提高 10.96 个百分点、EV F1 提高 3.42 个百分点（表 2）；完整输出分

别提高 10.27 和 3.44 个百分点。两库在 B2 相同，因此从 B3 起的分离衡量初次构库之后的进一步学习，而非获得任意技能的收益。

表 2. B1 之后 112 个训练流新来源的首答表现（%）。 每个来源贡献一个 EC 及一个 EV 回答。包含全部 B2–B8 预测；末行为进化库减固定 B1 库的配对均值，单位为百分点。

首次遇案时技能库	EC 原生 F1	EV 原生 F1	EC 完整输出 F1	EV 完整输出 F1
空库	63.21	61.43	66.56	61.29
B1 后固定库	80.87	84.74	84.15	83.97
进化库	91.83	88.16	94.42	87.41
进化 − 固定 B1，pp	+10.96	+3.42	+10.27	+3.44

真实请求确认了后续修订实际覆盖哪些任务。在 112 个后续 EC 任务中，86 个收到不同于固定 B1 的指导，其中 52 个原生 F1 提高、三个降低；EV 对应 96 个任务，其中 36 个提高、14 个降低。其余 26 个 EC 与 16 个 EV 任务输入相同，复用同一已记录响应。同案参照将库效用与批次之间的变化分开。例如，三个 EV 条件在 B7 均下降，但进化库仍高于固定 B1 2.25 个百分点；B8 的配对优势为 6.44 个百分点。图 2 保留这些观测波动，并展示每批的两种评分视图。

技能库主要通过修订已有程序进化。16 次教学步骤中有九次提交更新，包括五次 EC 和四次 EV。B1 之后，已接受编辑对已有任务投影进行 16 次修订，并新增一个 EV 投影，同时保持七条记录。最终技能库占用 3,993 tokens，每个后续首答任务实际收到两个或三个投影指令块（附录 D）。这些记录区分内容进化与条目数量增长。

终库比较进一步检验进化是否帮助另外的来源集合。在 128 个确认案件上，终库相对自身 B1 库将 EC F1 从 83.51%提高到 95.46%，配对增益 11.95 个百分点，同时调整区间为[7.33,16.60]。EV 从 84.25%提高到 87.90%，点估计增益 3.65 个百分点，调整区间为[-2.82,10.28]。因此，分类任务的继续学习收益延续到了学习流以外；估值点估计尚不构成调整后显著的继续学习效应。

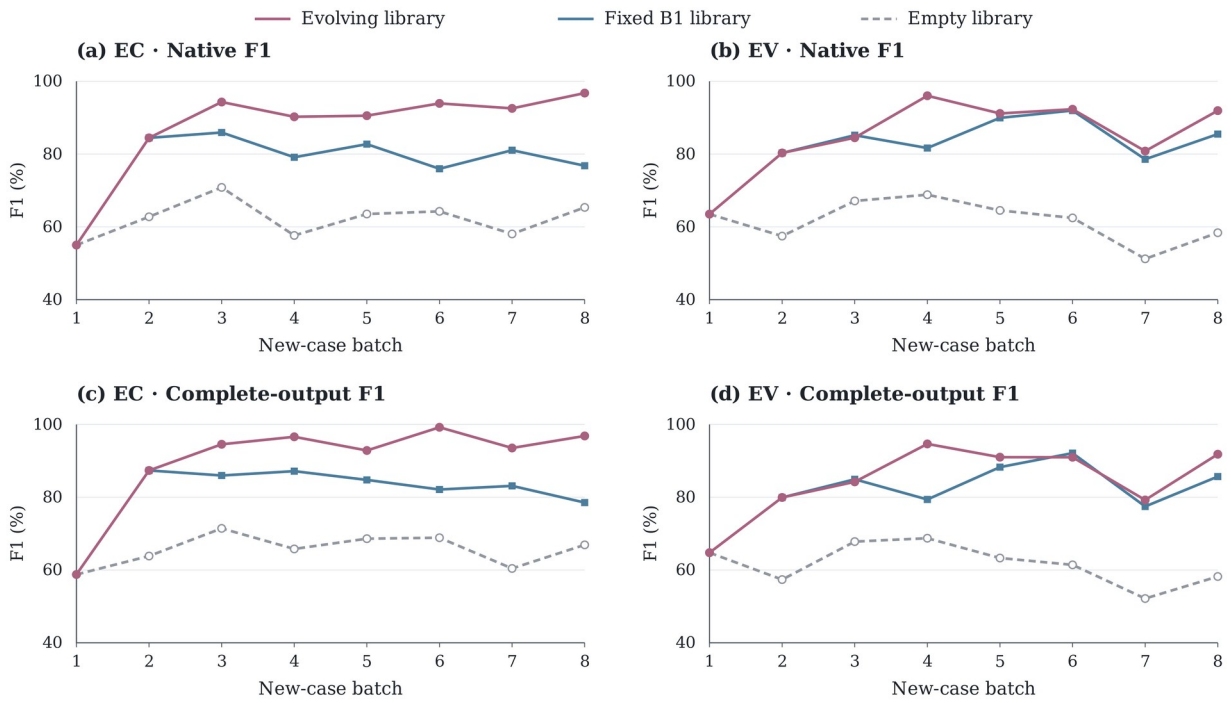


图 2. 持续进化在首批学成库之外改善后续新案表现。每个点为 16 个新来源案件的均值，其 EC 与 EV 首答均在当前目标释放前保存。各面板展示进化库、空库和固定首批库的原生与完整输出 F1。固定 B1 库从 B2 起可用，B1 从空库开始。完整展示八批观测，不进行平滑，不包含标签释放后的重放分数。

6.3. 执行证据与发布策略（RQ3、RQ4）

教师可见执行证据（RQ3）。 保留事实、法条、已释放目标及基于重放的准入、向教师隐藏显式执行结果，得到的终库 EC/EV F1 为 86.98/80.38%。完整方法分别提高 8.48 个百分点[3.91,13.59]和 7.53 个百分点[2.38,12.67]，方括号为同时调整的来源配对区间。这支持在所保留学习协议中，根据真实执行错误而非仅根据参考解修订程序。控制仍接收标签和公开已解材料，其控制器也通过重放与准入提供间接反馈。

时间顺序证据将这一效应与初次获取区分。在同一批 112 个 B1 后来源上，隐藏执行证据条件的原生 EC/EV F1 为 84.54/81.27%，自身 B1 快照对应 84.54/81.91%。其继续学习变化为 0.00/-0.64 个百分点，主方法则为+10.96/+3.42（表 2）。附录 D.5 报告两项完整控制及其学习路径边界。

准入与选择策略（RQ4）。 完整输出效用准入相对严格策略控制的 EC 优势为 15.17 个百分点，调整区间[10.53,20.35]。严格控制的 EV 点估计最高，为 89.01%，主方法为 87.90%；效用减严格的 EV 配对差为-1.11 个百分点[-6.20,3.65]。得到支持的策略优势因此是分类质量，而非每个端点均优于控制。由于控制同时改变准入与选择，比较检验的是策略束及其产生的学习路径，不是单独的计数否决效应。

完整回答质量。 主方法的完整输出 EC F1 为 96.67%、EV F1 为 87.51%，精确目标匹配为 57.81%与 41.41%（表 B3）。这些指标区分较高的声明覆盖与整份答案匹配。两条格式失败均作为 EV 零分结果保留。完整输出评价还保留未匹配或空目标资产上的额外申报，因此原生 F1 提高不意味着在补充质量评价中取消其代价。

7. 讨论

执行驱动的法律程序。 完整来源隔离评价表明，可编辑技能库能够明显改善小型冻结模型的法条回答。教师证据控制将这种效用与模型真实漏列、错金额及额外预测的信息相连。教师在学习期间参与；测试时，冻结执行器仍自行选择条款与金额。因此，学习状态是可复用指令，而非另一答题模型或享有特权的数值求解器。

初次获取之后的改进。 有用的初始库与有用的进化过程回答不同问题。自身 B1 参照固定初次获得的知识，后续程序则继续修订。配对比较支持进一步的分类改进，且在后续学习流新来源及独立冻结来源上均观察到。正的 EV 继续学习点估计在比较族调整后仍不确定。区分这些效应，可以检验持续学习，而不假设变化批次上的指标必须单调。

有界记忆内的进化。 学习流保持七条记录，在 B1 后修订 16 个已有任务投影并新增一个 EV 投影。真实下发轨迹与自身 B1 比较，将这些变化和后续案件所用指令相连。任务保护允许在共享记录内定向修订，完整输出检验则同时计入漏列与错误申报。记忆目标由此关注适用程序文本的效用，而非条目数量增长。

解释边界。 证据针对固定生成器内、已给事实、法条及法域先决步骤的法定替代任务。严格策略比较检验准入与选择的组合，不证明估值上一概占优。来源配对不确定性描述本次保留的学成库；独立学习构建在具备时另行报告。

8. 结论

任务专注执行教学与完整输出效用准入，将观察到的法律错误转化为冻结 8B 模型可用的技能。在 128 个 OpenExempt 新来源上，终库取得 95.46%的 EC F1 和 87.90%的 EV F1，并在首批技能库之外增加 11.95 个 EC 百分点。

附录 A. 学习算法与证据流转

A.1. 时间顺序技能库更新

每次构建期间，执行器参数、任务接口、解码配置和来源顺序保持固定。初始技能库为空。以下过程实现一个批次，其输出技能库成为下一批次的入批库。

1. **预测**。 对当前每个来源的两个任务视图，在入批库、空库和固定首批库条件下生成并保存回答。固定首批参照在 B1 期间为空，并在 B1 发布后立即设置。另保留初始固定库和直接数字空库两个参照别名，同样经过共同请求路径。本次构建的初始库为空，所有条件均直接生成数字申报。相同请求共享一次真实回答。
2. **释放**。 保存所有预测条件后读取当前来源目标。原始预测分数与后续教学、检验重放记录分开保存。
3. **EC 教学**。 组装真实父库、当前来源证据、选定历史证据和保留的 EC 提案反馈，请求一次带诊断的编辑。依据已释放证据、法律锚点、受保护 EV 投影及完整技能库 token 预算检查编辑。

4. **检验与选择**。 将通过检查且确有变化的提案在全部已遇到来源上执行。按照第 4.2 节检验整包提案和依赖一致分量。若组合库可准入，则核实其复用执行的完整请求身份。比较可准入整包与组合库，将选中修改作为下一步骤父库，或保持原父库。
5. **EV 教学**。 根据 EC 步骤的真实结果，对 EV 重复相同过程，并保护 EC 指令。两次机会分别对应不同任务，而非对较易提升任务反复尝试。
6. **批次发布**。 相对最初批父库检查最终技能库。保存实际库、两项教学决策、检验记录及父库到发布的谱系。恰在 B1 结束后，将实际发布复制为固定首批参照，后续不依据表现替换。

空操作、无效编辑或超预算提案消耗对应教学机会，不追加同任务重试。完整学习流返回实际 B8 发布。预先声明的后续损害停止规则检查从 B2 开始的两个连续批次：相对保留的空库、初始库或直接空库参照，EC/EV 平均原生分损失超过两个百分点；或相对初始库，EV 完整输出分损失超过两个百分点。触发时终止构建，不选择较有利的早期 checkpoint。固定首批库提供评价证据，不进入教学或准入。

A.2. 通信与执行证据

每个任务专注请求包含所有当前来源，并选取至多 16 个历史背景来源。先纳入保留失败的必要见证，再依次加入公开上下文见证、已观察回退及父库低分案件，以来源标识打破同分。若必要见证超过背景限额，则扩大限额以完整纳入。这是在已遇到训练数据内进行通信选择，提案检验仍覆盖全部已遇到来源。

请求内对公开法条材料去重。当前父库答案包含真实解析输出、原生及完整输出分数、逐声明错误。对选中父库执行，教师还可看到最终原生提交，以及模型实际生成推理的末尾至多 1,024 个字符。格式错误提交提供有界头尾片段。片段明确标识为未经核实的模型输出，不替代原回答或参考目标。

保留提案反馈标识历史候选及其原父库，当前父答引用则指向单独提供的观察。每任务至多保留一项未成功或部分提交的提案，并携带至多八条重放见证。控制器区分完整提交、部分提交和拒绝提案。执行器接收形成的程序，不接收来源标识、诊断标签或历史答案记录。

A.3. 完全相同请求核算

请求身份包含完整消息、回答 schema 及生成配置。仅有技能库 hash 不足以确定身份：不同库可以下发相同任务投影，而相关指令变化会产生不同请求。每项复用保留原始调用身份，并按照实际请求条件解码。依赖组合只有在每个组合请求匹配已测父库或提案请求时才有效。因此，组合选择一个固定技能库，不增加生成轮次，也不逐案按分数挑选答案。

固定采样 seed 是解码条件，不保证新发在线请求逐位相同，见所用版本的在线服务复现说明。完全相同请求复用共享原始已记录响应，不再发起一次重复生成。

成本报告对每个真实原始生成只计一次，将逻辑预测、检验视图和复用分开列示。教师响应与传输尝试是不同数量。服务端缓存输入属于输入 token 子集，推理 token 属于输出 token 子集，均不重复相加。各学习方法按真实 token 总量和耗时描述，而非假设计算成本相同。

附录 B. 预定冻结比较与不确定性

B.1. 来源与技能库边界

确认构建配方使用 seed 2026103001 固定 128 个来源，排除 15 个先前数据包共 564 案的来源 key。每个来源提供一个 EC 和一个 EV 问题。这是固定生成器内的来源隔离 IID 评价，不宣称未见法域或官方 Advanced 基准评价。

预定矩阵包含十个条件：空库、静态库、ACE 原生接口、ACE 共同接口、Text、进化 B8 库、自身固定 B1 库、严格策略控制、教师隐藏执行证据控制及已完成前序库。因此共有 2,560 条逻辑预测。两个 ACE 条件共享一个学成库；前序库是版本参照，而非匹配部件消融。

打开确认问题前，评价将每个真实学成库与其配置、冻结源码清单、完成记录、发布和终态保全绑定。B1 参照还绑定真实首批快照。学习源码快照确认不同教学版本共用的执行器及评分器。先保存所有条件预测，再读取确认目标统一评分。评价期间不进行教师更新或技能修订。

B.2. 分数与配对比较

每个条件、每个任务的主要均值，是 128 项原生逐案 F1 的算术平均。完整输出评分还匹配全部目标资产，并计入未匹配或空目标资产上的预测；在每案内汇总声明真阳性、假阳性及假阴性，再平均逐案分数。EC 对预测条款字符串去重；EV 使用固定声明匹配器及金额容差。无效输出保留零分，零分母约定遵循固定评分器。

对于一个固定比较对象，来源i提供进化库减去该对象的配对差。报告效应为 128 项差的均值，EC 与 EV 分别报告。来源配对 bootstrap 重采样完整来源索引，同时保留两个任务及所有条件。程序使用 NumPy PCG64、seed 2026103092、20,000 次抽样及 linear 分位数。

进化库分别与其余九个条件比较两个原生端点，共 18 项，组成一个主要比较族。报告普通 95%区间，以及分位数为$0.025/18$与$1-0.025/18$的 Bonferroni 调整区间。完整输出质量、精确目标分、错误类别及成本作为描述性补充证据。bootstrap 刻画以实际学成库为条件的来源变化，不替代独立学习构建。

B.3. 完整输出质量与无效回答

表 B3. 每个任务全部 128 案的补充质量端点（%）。 每格两个值依次为 EC / EV。精确目标匹配比较解码后完整答案与参考，格式失败依据原解析器。完整输出 F1 是在案内汇总声明后、再跨来源平均的分数，不是跨全部声明的全局比值。

冻结技能库	完整输出 F1 EC / EV	精确目标 EC / EV	无效数 EC / EV
强空库	66.65 / 56.51	11.72 / 8.59	0 / 1
静态法条技能库	63.64 / 56.37	9.38 / 8.59	0 / 3
ACE 原生接口	66.86 / 59.51	14.06 / 10.94	6 / 4
ACE 共同接口	69.73 / 66.41	17.19 / 14.84	1 / 1

冻结技能库	完整输出 F1 EC / EV	精确目标 EC / EV	无效数 EC / EV
Trace2Skill–Text	58.88 / 54.78	11.72 / 7.81	5 / 1
SkillCommit 论文适配	69.79 / 64.47	20.31 / 18.75	3 / 4
自身固定 B1 库	85.25 / 83.75	27.34 / 35.16	0 / 2
严格策略控制	81.60 / 88.28	26.56 / 44.53	2 / 1
教师隐藏执行证据控制	88.51 / 79.84	44.53 / 26.56	0 / 0
前序方法库	88.86 / 83.33	32.81 / 30.47	0 / 1
执行证据驱动技能进化	96.67 / 87.51	57.81 / 41.41	0 / 2

原十条件与 SkillCommit 补充合计 37 个无效输出，均对应输出长度终止并保留零分。主方法有两条这样的 EV 结果，SkillCommit 有三条 EC 和四条 EV 结果。原评分器未为这些格式错误回答提供完整汇总计数，因此不从有利子集或修复答案重建全局微平均。

B.4. 预定配对效应

表 B4. 进化库减比较对象的原生 F1 差（百分点）。 每格为配对效应及同时调整区间。全部 18 个 EC/EV 端点使用预定 Bonferroni 比较族，15 个调整后下界为正。普通 95%区间、逐案差值与来源 key 保留在机器可读结果中。

比较对象	EC 差 [调整区间]	EV 差 [调整区间]
强空库	+30.98 [24.80, 37.51]	+32.02 [23.79, 40.39]
静态法条技能库	+35.06 [28.48, 41.91]	+32.57 [24.69, 40.87]
ACE 原生接口	+30.46 [24.05, 37.49]	+29.22 [21.67, 37.30]
ACE 共同接口	+28.87 [22.97, 34.79]	+20.98 [14.63, 27.43]
Trace2Skill–Text	+40.39 [32.92, 48.30]	+34.59 [26.96, 42.55]
自身固定 B1 库	+11.95 [7.33, 16.60]	+3.65 [-2.82, 10.28]
严格策略控制	+15.17 [10.53, 20.35]	-1.11 [-6.20, 3.65]
教师隐藏执行证据控制	+8.48 [3.91, 13.59]	+7.53 [2.38, 12.67]
前序方法库	+7.83 [4.57, 11.16]	+3.99 [-1.66, 9.86]

EV 相对自身 B1、严格策略及前序库的调整区间跨零，不据此推断等效或非劣。表 B4 保留 `paper/tables/utility_frozen_results_20261101.json` 中的原比较族。表 1 和 B3 在其未改变的十条件行之外，加入 `paper/tables/utility_frozen_results_with_skillcommit_20261104.json` 中的 SkillCommit 补充。

B.5. 既有 TEST 上的 SkillCommit 补充

这项补充使用实际 SkillCommit 终库，评价既有、先前已观察的 128 来源 TEST 数据包。全部 256 条新预测均先保存，再执行其自身统一评分。来源配对重采样使用 20,000 次抽样、seed 2026110101，EC 与 EV 共享来源索引抽样。声明的两端点族采用 0.0125 和 0.9875 分位数构造同时 95%区间，与未改变的原 18 端点族分开。区间以这些实际冻结库为条件，不衡量独立学习构建变化。

表 B5. 主方法减 SkillCommit 论文适配的原生 F1 差（百分点）。

任务	配对差	普通 95%区间	两端点调整区间
EC	+27.49	[23.46, 31.70]	[22.92, 32.30]
EV	+23.08	[18.23, 27.94]	[17.55, 28.68]

附录 C. 经验技能库的构建条件

保留的 ACE、Trace2Skill–Text 与 SkillCommit 适配使用相同 128 个训练来源及原 EC/EV 参考输出。其配置与主方法具有相同 Qwen3-8B 解码设置，均请求 `gpt-5.6-sol` 及 high 推理强度。ACE 每次实际使用的反思均接收参考和真实预测；Trace2Skill–Text 分析 256 条空库轨迹时均接收参考、分数和实际输出。这些是面向任务接口的适配，而非作者代理环境的复现。

学习条件	技能库构建方式	执行器记忆 token 上限	教师响应
执行证据技能进化	在线任务专注修订及效用准入	4,096	使用 16 次
ACE 适配	在线反思、重新生成及增量策展	8,192	保留学习流使用 423 次
Trace2Skill–Text	离线轨迹分析、分层合并及文本翻译	8,192	使用 321 次
SkillCommit 论文适配	任务级在线修补及行为验证整合	8,192（前 4 条记忆）	使用 930 次

ACE 保留学习流包含 415 次反思及八次批次策展。续接记录还单独保留 19 次成功但未提交的教师响应；失败请求的用量为未知，而非零。Trace2Skill–Text 使用 256 次轨迹分析、64 次合并和一次翻译，随后训练重放不用于选择终库。历史构建调度和预算与主方法的四 worker 学习调度分开。最终比较在这些冻结库上统一执行器推理条件，构建成本另行报告。

SkillCommit 对失败首答先使用独立的训练目标辅助教师参考，经原生评分器验证后，最多尝试三次局部修补。EC 与 EV 使用独立记忆池。整合过程使用最多四个检索候选、三分之二行为阈值、每个活动候选两个反向见证及最多三个抽象版本。提交前重放完整支持范围；至少含两个来源的支持子集也可缩小范围并重新验证一次，同时保留父模式和未覆盖的局部补丁。本地 BGE 嵌入替代论文的嵌入服务。推理时，公开查询检索同任务最多四条完整记忆，实际下发受 8,192-token 上限约束，而非限制整个记忆池。完整构建包含 21 条高层模式和 23 条残余补丁。全部 256 个 TEST 任务均收到四条完整模式，实际记录 1,351 至 1,615 tok

ens。测试下发覆盖六条不同 EC 模式和四条 EV 模式，每个 EV 任务均收到同样四条，残余补丁未被选中。这些是声明的本地编码器适配下的实际部署计数。

附录 D. 实测技能演化与计算成本

D.1. 已发布技能库变化

表 D1 报告实际提交的任务投影，而非提案操作。一个共享记录可包含分开的 EC 与 EV 块，因此新增任务投影不一定增加记录。每批每任务各有一次教学机会。

批次	记录数	EC / EV 块	序列化 tokens	已提交 EC 投影编辑	已提交 EV 投影编辑
B1	7	7 / 6	2,461	新增 7	新增 6
B2	7	7 / 6	3,257	修订 4	修订 5
B3	7	7 / 6	3,413	修订 3	0
B4	7	7 / 6	3,413	0	0
B5	7	7 / 6	3,594	修订 1	0
B6	7	7 / 6	3,654	修订 2	0
B7	7	7 / 7	3,975	0	新增 1
B8	7	7 / 7	3,993	0	修订 1

B1 之后，每个首答任务实际收到两个或三个由公共任务及已给法域选择的指令块。下发记录确认执行器收到了哪些指令，回答分数衡量这些指令是否有帮助。预测使用实际入批的已发布库，因此 B8 首答之后的编辑进入终库比较，不追溯计入 B8 曲线。

教师隐藏执行证据控制最终保留 12 条记录，占用 3,965 tokens。它在 B6 之后保留两次修订、B8 之后保留一次修订。B6 修订下发给 B7–B8 首答，B8 修订则在冻结库比较中首次用于新案。

D.2. 实际构建成本

总量覆盖本次完整学习构建，包括其预测参照条件和训练检验重放。每个真实原始生成仅计一次；完全相同请求复用保留该次已记录响应。

数量	实测值
真实原始生成次数	1,207
完全相同请求复用次数	3,497
原始生成输入 / 输出 tokens	8,293,891 / 3,196,466
成功教师响应 / 已记录尝试	16 / 16
教师输入 / 输出 tokens	1,778,335 / 66,439
缓存输入 / 推理输出子集	115,968 / 38,939
服务总耗时	9.00 h

缓存输入已包含在教师输入中，推理输出已包含在教师输出中。服务总耗时根据管理器的单调时钟启动及成功事件计算，包含教师等待、CPU 工作和终态保全，不是活跃 GPU 小时的测量。冻结测试推理及其他学习构建不计入这些总量。

D.3. 保留构建中的教师与执行器工作量

主方法构建的教师 token 少于三项保留经验适配中的每一项（表 D3）。相对保留的 SkillCommit 适配，在实测构建调度下，教师输入 tokens 减少 90.97%，真实执行器生成减少 40.10%。本地计数包含各构建实际记录的首答、预测参照条件及训练检验重放。教师与执行器使用不同模型，因此分别报告 token；各方法构建预算不同，不能据此推算共同的 GPU 耗时或货币成本。

表 D3. 实际保留学习流的响应生成量。 教师输入包含缓存输入，教师输出包含推理输出。构建调度与记忆预算见附录 C。

学习条件	角色	响应数	输入 tokens	输出 tokens
执行证据技能进化	教师	16	1,778,335	66,439
执行证据技能进化	8B 执行器	1,207	8,293,891	3,196,466
严格策略控制	教师	16	1,776,813	67,501
严格策略控制	8B 执行器	1,206	8,172,956	3,466,541
教师隐藏执行证据控制	教师	16	904,633	46,046
教师隐藏执行证据控制	8B 执行器	974	6,587,209	2,416,560
ACE 适配	教师	423	11,526,040	405,699
ACE 适配	8B 执行器	896	7,122,372	2,258,447
Trace2Skill–Text	教师	321	6,429,967	503,252
Trace2Skill–Text	8B 执行器	512	4,061,370	1,463,066
SkillCommit 论文适配	教师	930	19,696,279	548,224
SkillCommit 论文适配	8B 执行器	2,015	13,663,563	5,542,122

ACE 运行续接还退役了 19 次成功教师响应，包含 458,657 输入及 21,354 输出 tokens，以及 15 次执行器生成，包含 135,867 输入及 45,681 输出 tokens。这些用量与保留学习流总量分开保全。失败请求中未报告的用量保持未知，不记作零。

四次在 TEST 前退役的 SkillCommit 实现尝试另有 368 次成功教师响应（7,640,289 输入及 234,308 输出 tokens）和 584 次执行器生成（3,893,280 输入及 1,620,559 输出 tokens）。这些输出和记忆未导入保留构建。保留构建的 930 次成功教师响应来自 931 次已记录尝试，未报告的失败请求用量保持未知。345 次完全相同请求复用不增加真实原始生成次数。表 D3 的学习总量不含冻结测试推理。

D.4. 已完成冻结评价成本

十条件冻结比较使用 2,560 次真实生成，不复用前阶段答案，也没有完全相同请求别名。执行器输入/输出总计 19,242,658/6,841,407 tokens，教师调用为零。原完成记录的墙钟时长为 19 小时 50 分 03 秒，覆盖全部条件，并非活跃 GPU 小时或主方法单独的推理成本。保留原 2,530 次 stop 及 30 次 length 结果。全部预测先于统一目标读取和评分。

单独的 SkillCommit 冻结评价使用 256 次新增真实生成，输入 2,001,690 tokens、输出 712,116 tokens，教师调用为零。全部 249 次 stop 和七次 length 结果均保留。这些推理总量与表 D3 中的完整学习成本分开。

表 D4. 冻结评价的实际执行器 token 用量。 每个条件包含相同的 256 个 EC/EV 任务，token 计数包含达到输出上限的回答。

条件	输入 tokens	输出 tokens	达到输出上限的回答数
空技能库	1,622,317	711,638	1
纯法条静态库	1,838,793	627,485	3
ACE 原生接口	2,267,693	694,380	10
ACE 共同接口	2,200,621	653,265	2
Trace2Skill–Text	2,438,957	661,951	6
SkillCommit 论文适配	2,001,690	712,116	7
执行证据驱动进化	1,809,329	627,240	2
自身冻结 B1	1,752,541	785,144	2
严格策略控制	1,767,439	723,505	3
隐藏显式执行证据	1,766,569	621,900	0
前序技能库	1,778,399	734,899	1

在这组相同任务上，进化库比 ACE 共同接口少用 17.78%的输入 tokens 和 3.98%的输出 tokens，比 SkillCommit 适配少用 9.61%的输入 tokens 和 11.92%的输出 tokens。相对空库，其输入用量增加 11.53%，输出用量减少 11.86%。输入与输出计数分别描述执行器的不同资源用量，技能库构建成本另行统计。

D.5. 机制控制的学习路径证据

表 D5. 相同 112 个 B1 后来源上的时间顺序首答（%）。 这些是学习流预测，不是确认成绩或标签后重放。

学习条件	EC 原生 F1	EV 原生 F1	EC 完整输出 F1	EV 完整输出 F1
执行证据驱动技能进化	91.83	88.16	94.42	87.41
严格策略	76.31	83.49	78.70	83.04
隐藏执行证据	84.54	81.27	87.15	80.36

严格策略的 B1 库没有 EV 投影，因此后续 EV 相对该快照的增益也包含初次获取，不是匹配的获取后效应。在固定主方法已记录输出的核对中，全部九次真实提交也满足严格门槛。因此，完整构建的差异不能仅归因于计数否决：策略及其诱发的教学路径共同变化。

隐藏执行证据条件保留已释放目标及公开已解材料。其固定 B1 原生 EC/EV F1 为 84.54/81.91 %，完整输出继续学习变化为 0.00/-0.72 个百分点，主方法对应+10.27/+3.44。向教师隐藏显式执行证据不等于移除控制器反馈，也不证明仅凭标签不能形成有用技能。

附录 E. 补齐独立适用的法律替代依据

以来源隔离冻结评价中的 3000055 案说明程序进化。题目给定的先决信息允许使用联邦及 Wisconsin 豁免。资产是一条价值 890 美元的项链、一套价值 175 美元的浴巾和一件价值 8,300 美元、由医生授权使用的义肢。针对义肢，基准参考包含三个独立替代：11 U.S.C. § 522(d)(9)、11 U.S.C. § 522(d)(5)和 Wis. Stat. § 815.18(3)(d)。按给定任务材料，每项 EV 替代的保护金额均为 8,300 美元。这些是替代请求，不是可以相加的支付金额。

实际技能演变。 B1 联邦 EC 指令已经要求一般财产豁免独立适用，并与专门条款并存。B2 增加了单独的最终一般财产豁免检查，B3 则将程序明确为两次必做扫描，并逐资产审查完整性。Wisconsin 的 EV 执行块首次在 B7 发布，B8 再次修订。最终库保存的 EV 请求包含联邦、跨法域扫描及 Wisconsin 三个 EV 投影；B1 请求包含前两个，但没有 Wisconsin 的 EV 投影。这些修订均在冻结评价之前发布。

表 E1. 完整示例案件的原生 F1（%）。 所有数值来自共同执行器设置下保存的原始预测。

冻结条件	EC F1	EV F1
空技能库	80.00	44.44
自身冻结 B1	93.33	83.33
隐藏显式执行证据	80.00	93.33
最终进化库	100.00	100.00

关键观察。 尽管一般原则已存在，B1 的 EC 回答仍漏掉义肢的一般财产豁免；其 EV 回答只报告规定医疗辅助器具的条款，漏掉一般财产及 Wisconsin 两个替代。最终库的原始输出补齐了三个替代及其金额。空库 EV 回答还把不相关的账户、经营财产及车辆条款赋给义肢，说明不能只看召回。对三件资产，最终 EC 和 EV 输出各补齐全部九个参考声明，且没有额外声明。该案把实际指令下发及内容修订与最终法律声明集合联系起来，全部来源的对照则衡量技能库的总体效用。

参考文献

Dalla Noce, Niko, Davide Bacciu, Sina Farhang Doust, 和 Lorenzo De Mattei. 2026 年. 《JustifIT-QA: Evidence-Grounded Legal Question Answering in Italian》. *Proceedings of the 2026 Conference on Empirical Methods in Natural Language Processing*, 13661〜85. https://aclanthology.org/2026.emnlp-main.593/.

Guha, Neel, Julian Nyarko, Daniel E. Ho, Christopher Ré, 等. 2023 年. *LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models*. https://doi.org/10.48550/arXiv.2308.11462.

He, Yu, 和 Weikai Yang. 2026 年. *SkillCommit: Evolving Agent Skills through Behaviorally Validated Scope Expansion*. https://doi.org/10.48550/arXiv.2608.15165.

Holzenberger, Nils, 和 Benjamin Van Durme. 2021 年. 《Factoring Statutory Reasoning as Language Understanding Challenges》. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, 2742〜58. https://doi.org/10.18653/v1/2021.acl-long.213.

Ni, Jingwei, Yihao Liu, Xinpeng Liu, 等. 2026 年. *Trace2Skill: Distill Trajectory-Local Lessons into Transferable Agent Skills*. https://doi.org/10.48550/arXiv.2603.25158.

Ouyang, Siru, Jun Yan, I-Hung Hsu, 等. 2025 年. *ReasoningBank: Scaling Agent Self-Evolving with Reasoning Memory*. https://doi.org/10.48550/arXiv.2509.25140.

Qwen Team. 2025 年. *Qwen3 Technical Report*. https://doi.org/10.48550/arXiv.2505.09388.

Servantez, Sergio, Sarah B. Lawsky, Rajiv Jain, Daniel W. Linna Jr., 和 Kristian Hammond. 2026 年. *OpenExempt: A Diagnostic Benchmark for Legal Reasoning and a Framework for Creating Custom Benchmarks on Demand*. https://doi.org/10.48550/arXiv.2601.13183.

Yang, Chen, Jiashuo Tian, Ziqi Wang, Xinyin Liu, Meiru Ye, 和 Junjie Chen. 2026 年. *Learning Globally Reusable Skills for Coding Agents*. https://doi.org/10.48550/arXiv.2608.06153.

Zhang, Qizheng, Changran Hu, Shubhangi Upasani, 等. 2025 年. *Agentic Context Engineering: Evolving Contexts for Self-Improving Language Models*. https://doi.org/10.48550/arXiv.2510.04618.

Zhao, Andrew, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, 和 Gao Huang. 2024 年. 《ExpeL: LLM Agents Are Experiential Learners》. *Proceedings of the AAAI Conference on Artificial Intelligence* 38 (17): 19632〜42. https://doi.org/10.1609/aaai.v38i17.29936.